

Aquisição e Condicionamento de Sinais por EOG usando Redes Neurais para Controle de Cadeira de Rodas Motorizada

Douglas J. C. dos Santos, Patric J. Marques, Marilda M. Spindola

Universidade de Caxias do Sul, Francisco Getúlio Vargas 1130, Caxias do Sul
Fone: +55 54 3218-2100, djcsantos@ucs.br

Abstract - In this article, the methods, procedures and strategies used in the improvement of the Electro-oculography Signed Motorized Wheelchair [1], project with the proposal to improve the control of the prototype making the use of the Artificial Neural Networks.

Resumo - Neste artigo, são abordados os métodos, procedimentos e estratégias utilizadas no aprimoramento do projeto Cadeira de Rodas Motorizada Controlada por Sinais de Eletro-oculografia [1] com a proposta de aprimorar o controle do protótipo empregando o uso das Redes Neurais Artificiais.

1 Introdução

De acordo com dados do IBGE, a população brasileira possuía um total de 190,7 milhões de habitantes em 2010, portadores de deficiência severa visual, auditiva e motora. Apesar de representarem 23,9% da população, o país não fornece sistemas adaptados para suas necessidades [7] e [8].

Utilizando tecnologias para Interfaces Humano-Computador - IHC, aquisição de biosinais por EOG (eletro-oculografia), processamento de sinais e redes neurais, realizou-se o projeto Cadeira de Rodas Motorizada Controlada por Eletro-oculografia Utilizando Redes Neurais. Esta cadeira visa auxiliar a locomoção de pessoas portadoras de deficiências motoras, cuja enfermidade atinge os membros superiores e/ou inferiores do corpo humano. O comando para a movimentação da cadeira é dado pelos sinais EOG coletados por quatro eletrodos posicionados na região ocular do usuário: laterais, inferior e superior do olho, respectivamente os sentidos de locomoção da cadeira: laterais, para trás e para frente [1]. O deslocamento da cadeira se dá linearmente ao movimento do olhar, não havendo diferença entre o posicionamento do olho mais para baixo ou mais para cima, nesta primeira versão implementada. O projeto de controle dos motores é que faz o deslocamento ser suave entre um movimento de avanço e um giro para a esquerda, por exemplo. O objetivo principal deste trabalho é encontrar um modelo em rede neural que identifique padrões de sinais de EOG que representem comandos de

deslocamento da cadeira de rodas motorizada. O presente artigo propõe apresentar o desenvolvimento do tratamento de sinal advindo do EOG referente ao movimento ocular quando no comando da cadeira de rodas motorizada. As questões referentes ao sistema de aquisição e posicionamento de eletrodos, bem os possíveis desconfortos causados no usuário são tratados na publicação I2MTC – 2017 [1].

2 Processamento dos Sinais EOG por Redes Neurais

O processamento dos Sinais EOG é executado através de métodos denominados por *Algoritmos de Aprendizagem*. A função destes é fortalecer as conexões entre os neurônios artificiais, conhecidos como pesos sinápticos. A alteração dos valores destes permite uma simulação para encontrar uma resposta coerente de determinado impulso de entrada, efetuando assim a concretização do conhecimento adquirido [3].

2.1 Neurônio artificial

O neurônio é a unidade de processamento fundamental para o funcionamento da rede. A Fig. 1 ilustra o modelo matemático de aprendizagem supervisionada do *Perceptron de Camada Única*, proposto por Frank Rosenblatt em 1958 [3].




Figura 1 - Perceptron de Camada única

O modelo é composto essencialmente por *Camada de entrada* (x_m), caracterizada por captar as informações conhecidas do ambiente e transmiti-las para o neurônio; *Camada de pesos* (w_{km}), descreve a relevância do neurônio, podendo tornar um neurônio extremamente relevante para determinar um padrão, ou tornar o mesmo irrelevante; *Somador* (Σ), responsável por acumular todas as variáveis w_{km} ponderadas; *Bias* (b_k), termo

excedente para ajustar a saída com valor não nulo correspondente a uma excitação de valores nulos; *Função de Ativação* ($\varphi(\cdot)$), é o processo de filtragem da saída da rede; *Saída* (y_k), armazena o termo que está sendo modelado [3]. Assim, excitações foram inseridas na *camada de entrada*, multiplicadas por seus respectivos *pesos*, somados juntamente com o *bias* e passado pela *função de ativação*. O processo descrito até então chama-se *Feedforward*, porém o neurônio não reconheceu nenhum padrão, o ajuste dos pesos sinápticos que determina o aprendizado ocorre posteriormente na etapa denominada *Backpropagation* [4].

2.2 Aprendizagem

Levando em consideração o grafo da Fig. 2, o estágio de aprendizagem está entre os valores de $y(i)$ e $d(i)$. Como se trata de um algoritmo de aprendizado supervisionado, ainda existe uma última camada, chamada de *Camada de Valores Conhecidos*, essa camada possui os valores de saída reais correspondente às excitações que ocorrem na entrada da rede. Esta serve para indicar a direção em que os pesos da rede devem ser ajustados para que a mesma consiga reconhecer os padrões que estão sendo fornecidos [5].




Figura 2 - Grafo do Processo de Aprendizagem

Equacionando e descrevendo todas as etapas do modelo teremos:

- Valores inseridos na camada de entrada, descritos por:

$$x(i) = [x_1(i), x_2(i), \dots, x_m(i)]^T \quad (1)$$

- Pesos gerados randomicamente:

$$w(i) = [w_1(i), w_2(i), \dots, w_m(i)]^T \quad (2)$$

- Como se trata apenas de um único neurônio, teremos que a saída do mesmo será igual a camada de saída, isto é, $v(i)$ idêntico à $y(i)$. Essa saída é obtida a partir da multiplicação matricial de $x(i)$ por $w(i)$, passando pela função de ativação, ou seja:

$$v(i) = y(i) = \varphi(x^T(i)w(i)) \quad (3)$$

- A função de ativação φ utilizada foi a Sigmoid, pelo fato de retornar uma probabilidade, ou seja, ela resulta a chance de o valor gerado pela rede neural estar correto, a Sigmoid é caracterizada por:

$$\varphi(i) = \frac{1}{(1+e^{-x})} \quad (4)$$

- Com o valor de $y(i)$ se faz necessário algum parâmetro para saber se o vetor gerado está correto, para isto, se utiliza o erro entre o resultado da rede e a camada de valores conhecidos, definida por:

$$d(i) = [d_1(i), d_2(i), \dots, d_m(i)]^T \quad (5)$$

- Devido à necessidade de ajustar os pesos em determinada direção, isto é, aumentar ou diminuir o valor dos pesos de acordo com $y(i)$, precisamos de um parâmetro de referência. O método utilizado foi a derivada da função de erro em relação aos pesos, portanto a função de erro deve ser diferenciável, no caso:

$$e(i) = \frac{1}{2} (d(i) - y(i))^2 \quad (6)$$

- Efetuando a diferenciação obteremos o seguinte ajuste nos pesos:

$$w(n+1) = w(n) + \eta x(n)e(n) \quad (7)$$

Onde a constante η se trata de uma taxa de aprendizado, para evitar que os pesos possam convergir para valores distantes da solução.

Após realizar o processo de Feedforward e realizar os ajustes do Backpropagation definidos na equação 6, a rede neural irá convergir para os valores desejados que se encontram em $d(i)$ [6].

3 Aquisição de Sinais

Os sinais foram adquiridos pelo circuito de EOG em diferentes baterias de testes. O usuário deveria se deslocar com os movimentos dos olhos, onde a cadeira realizava sua locomoção de acordo com a direção escolhida. A Fig. 3 representa os movimentos para cima e para baixo (canal vertical). A máxima amplitude do sinal foi de 48 mV enquanto que a máxima amplitude do ruído foi de 3.2 mV [1].




Figura 3 - Resposta do Canal Vertical

O canal horizontal (responsável por capturar os movimentos horizontais) mudou 20% em comparação com o canal vertical durante movimentos verticais (movendo o olho para cima e para baixo). Mesmo quando o olho realiza movimentos verticais, o canal horizontal irá captar algum sinal pois depende da posição dos eletrodos sobre e abaixo do olho. Entretanto, o sinal do canal vertical é suficientemente distinguível para indicar algum controle na cadeira de rodas. A tensão

máxima para o canal vertical foi de aproximadamente 65 mV. A Fig. 5 mostra a comparação dos dois canais simultaneamente, onde ambos canais apresentam respostas semelhantes, porém com amplitudes distintas.




Figura 4 - Resposta do Canal Horizontal




Figura 5 - Comparação dos Canais

Verificou-se teste de repetitividade do sinal, que descreve a propriedade de um sistema responder de forma igual quando submetido a diversos testes sob as mesmas condições. Foram superpostas 3 curvas de cada canal mudando as direções do olhar. Na Fig. 6, o canal horizontal representa o olhar para esquerda com um pico máximo medido de 65,6 mV. A Fig. 7 indica o mesmo canal, porém o usuário estava com o olhar direcionado para a direita, onde o pico máximo foi de -36 mV. A Fig. 8 descreve o sinal captado no canal vertical com o utilizador da cadeira olhando para cima, resultando em um pico de 77,5 mV. Por fim, a Fig. 9 indica o canal vertical olhando para baixa, com a tensão máxima de -48 mV [1]. O processamento inicial desses dados foi realizado diretamente no hardware da cadeira, gerando reações inesperadas no controle dos atuadores. Portanto houve a necessidade de utilizar redes neurais para o tratamento das informações, aprimorando o movimento do dispositivo.




Figura 6 - Canal horizontal com movimento para a esquerda




Figura 7 - Canal horizontal com movimento para a direita




Figura 8 - Canal vertical com movimento para cima.




Figura 9 - Canal vertical com movimento para baixo.

4 Tratamento de Dados

A primeira etapa a se realizar é o janelamento das ondas referentes ao movimento do usuário, amenizando oscilações com a remoção dos ruídos. Para efetuar o tratamento, se desenvolveu um software para computar a derivada numérica das ondas, encontrando assim o ponto onde a inclinação era zero, ou seja, o ponto máximo do pico da onda em questão. O tamanho da janela foi definido por 130 valores de tensão, equivalente à 130ms de dados. Com o valor de pico, o centro da onda foi determinado por esta informação. Um vetor com tamanho de 130 foi formado, utilizando os 65 valores anteriores e posteriores, gerando assim a janela do sinal. O resultado é ilustrado na figura 10.

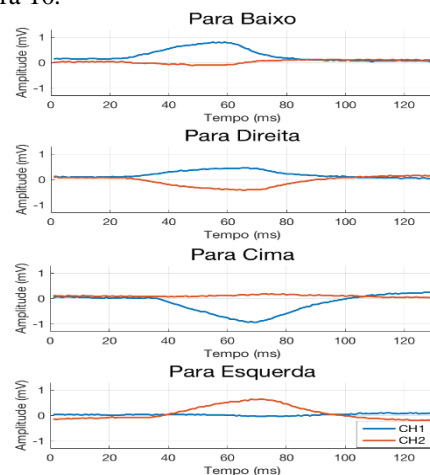


Figura 10 - Janelamento do Sinal

5 Implementação da Rede

O algoritmo utilizado para realizar o aperfeiçoamento da cadeira de rodas foi o Multilayer Perceptron, constituído tipicamente por n camadas de neurônios Perceptron Simples como segue na imagem 11.




Figura 11 – Multilayer Perceptron

A linguagem utilizada para implementação foi Python devido sua ampla aplicação em inteligência artificial, o framework base que funciona como core para outras bibliotecas utilizado no projeto foi o TensorFlow, se trata de uma biblioteca de software de código aberto para computação numérica. Este framework funciona como base para o scikit-learn, que foi utilizada por possibilitar a implementação do Multilayer Perceptron. A topologia da rede implementada é caracterizada por: camada de entrada com 40 neurônios recebendo 260 informações por iteração, 130 pelo canal vertical e outras 130 pelo canal horizontal, duas camadas ocultas, uma com 80 neurônios e outra com 120, e pôr fim a camada de saída com 5 neurônios, correspondentes aos movimentos possíveis e oscilações, ou seja, cima, baixo, direita, esquerda e ruído. O conjunto de dados possui um total de 828 amostras, onde cada amostra é constituída por 120 valores de tensão, para realizar o treinamento da se utilizou 66,67% deste conjunto e o restante para validação. Após o treinamento da rede em que se foi realizada 500 iterações sobre o conjunto de treinamento, a rede conseguiu atingir uma precisão de 93% durante a validação, ou seja, dos dados que nunca foram apresentados durante o treinamento, a rede gerou a resposta correta em 255 das 273 amostras. A matriz da Figura 12 caracteriza os resultados obtidos, onde as colunas representam o comando esperado pela rede e as linhas o comando gerado pela rede.

COMANDO	ESQUERDA	DIREITA	CIMA	BAIXO
ESQUERDA	68	2	3	0
DIREITA	1	71	0	5
CIMA	0	0	64	0
BAIXO	1	4	2	52

Figura 12 - Matriz de Resultados

As respostas erradas dadas pelo sistema, ainda neste protótipo, deverão ser tratadas com novos filtros, ainda não implementados nesta versão.

6 Conclusão

Como a aquisição dos dados de entradas da rede foram realizados somente em uma pessoa e em pequena escala os resultados obtidos foram

satisfatórios, porém, é possível que a rede neural possa estar “viciada”. O “sistema aprendeu” os padrões cerebrais relativos a essa única pessoa e assim, a comparação com novas aquisições advindas da mesma pessoa, torna o sistema muito mais confiável. Para que aconteça um aperfeiçoamento na rede neural seria necessário um banco de dados que fosse alimentado constantemente com sinais de diversas pessoas e em grande escala, para que a rede pudesse aprender um padrão cerebral generalizado.

Referências

- [1] PERIN, M. D. R. ; PORTO, R. W. ; NETO, A. Z. ; SPINDOLA, M. M. . EOG analog front-end for human machine interface. In: 2017 IEEE International Instrumentation and Measurement Technology Conference (I2MTC), 2017, Torino. 2017 IEEE International Instrumentation and Measurement Technology Conference (I2MTC), 2017. p. 1.
- [2] CARVALHO, André Carlos Ponce de Leon Ferreira et al. Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina. 1. ed. [S.l.]: LCT Editora, 2011. 396 p.
- [3] HAKIN, Simon. Redes Neurais: Princípios e prática. 2. ed. [S.l.]: Bookman, 2017. 908 p.
- [4] MOTOKUCHO, T.; ODA, P., “Vision-based human-following control using optical flow field for power assisted wheelchair,” IEEE International Workshop On Advanced Motion Control, 2014, Yokohama, Japão, p. 266–271.
- [5] WU, B. et al., “Accompanist detection and following for wheelchair robots with fuzzy controller,” IEEE International Conference On Advanced Mechatronic Systems, 2012, Tokyo, p. 638–643.
- [6] RASHID, Tariq. Make Your Own Neural Network: A gentle journey through the mathematics of neural networks, and making your own using the Python computer language. 1. ed. [S.l.]: Createspace Independent Publishing Platform, 2016. 224 p.
- [7] CENSO Demográfico 2010: Característica gerais da população, religião e pessoas com deficiência. 1. 2010. Disponível em: <https://biblioteca.ibge.gov.br/visualizacao/periodicos/94/cd_2010_religiao_deficiencia.pdf>. Acesso em: 30 nov. 2018.
- [8] PESQUISA de Informações Básicas Municipais. 2010. Disponível em: <<https://ww2.ibge.gov.br/home/estatistica/economia/perfilmunic/default.shtm>>. Acesso em: 30 nov. 2018.